

Informe Final Individual — Aprendizaje Profundo (59003)

Red Neuronal Convolutacional para Reconocimiento de Expresiones Faciales (FER-2013)

Jorge Quizamánchuro Fuel | MIA-B | Universidad Internacional del Ecuador

Docente: Ing. Jefferson David Rodríguez Chivata | Junio, 2026

1. Descripción del dataset y del problema

El reconocimiento automático de expresiones faciales es relevante para plataformas de psicoeducación y monitoreo de bienestar emocional contextos que motivan *Psico Platform*, mi línea de aplicación profesional. Como caso académico utilizo **FER-2013** (Goodfellow et al., 2013): 35.887 imágenes de rostros en escala de grises a 48×48 píxeles, etiquetadas en siete expresiones (**angry**, **disgust**, **fear**, **happy**, **neutral**, **sad**, **surprise**). El conjunto presenta un **desbalance fuerte**: **happy** reúne 7.215 imágenes de entrenamiento frente a **disgust** con apenas 436 (razón 16,5:1), lo que vuelve inadecuada la *accuracy* y obliga a priorizar F1-macro.

2. Metodología

Implementé una **CNN desde cero** con dos bloques convolucionales (Conv2D 32 y 64, kernel 3×3 , ReLU), **Flatten**, una densa de 128 y **softmax** de 7 unidades. Centralicé el diseño en una función `build_cnn(...)` con *flags* para activar BatchNormalization, Dropout y aumentación; esto garantiza que las tres variantes evaluadas (**A**-Baseline, **B**-Regularizada, **C**-Aumentada) compartan topología y cualquier diferencia sea atribuible al cambio activado. El pre-procesamiento mantuvo la resolución nativa 48×48 grayscale con `Rescaling(1/255)` embebido en el modelo. Los splits siguieron 85 %/15 % sobre **train** (semilla 42) reservando **test** como caja cerrada. Usé `sparse_categorical_crossentropy` sobre etiquetas enteras evitando el OHE manual en línea con el feedback de la Semana 1, optimizador Adam ($lr=1e-3$), batch 64, máximo 25 épocas con `EarlyStopping(patience=5)` y `ReduceLROnPlateau`. Tras una primera iteración con Dropout 0,5 y `class_weight` que produjo *underfitting* catastrófico, calibré la variante B con Dropout 0,20/0,30 sin `class_weight`: decisión empírica que reflejó la lección recurrente del cuatrimestre los hiperparámetros de regularización se calibran al problema, no se asumen.

3. Resultados y análisis

La variante **B** alcanzó el mejor F1-macro sobre *test*: **0,5032** (Accuracy 0,5415), superando al *baseline* A ($F1 = 0,4292$) en **+7,4 puntos porcentuales**. La variante C, que añadía aumentación sobre B, retrocedió a $F1 = 0,2920$ evidenciando que apilar defensas sobre una red pequeña ($\approx 1,2$ M parámetros) deriva en *underfitting* antes que en mejor generalización. El patrón observado $A < B > C$ contradice la hipótesis monotónica de partida y, junto al hallazgo análogo de Semana 1 con L2, consolidó un principio metodológico que estructuró el resto del cuatrimestre. El análisis por clase identificó **disgust** como el cuello de botella (recall 0,42), confirmando que el desbalance es el techo real del modelo la siguiente iteración debería atacarlo con un *backbone* más rico o con datos sintéticos balanceados, no con más regularización.

Repositorio público: github.com/georgenton/UIDE-Aprendizaje-Profundo — carpeta *semana-2/* para notebook completo, informe técnico y outputs.