

Perceptrón Multicapa para predicción de búsqueda de tratamiento en salud mental

Maestría en IA Aplicada · UIDE · MIA-B · Aprendizaje Profundo (59003) · Semana 1

Autor: Jorge Quizamán Churo

Notebook: MLP_Mental_Health_Survey.ipynb

Dataset: OSMI Mental Health in Tech Survey 2014

Framework: TensorFlow / Keras

1. Contextualización del problema

Las plataformas digitales de salud mental enfrentan un reto operativo común: priorizar a quién acercarse primero entre miles de usuarios. Predecir con qué probabilidad una persona *buscaría tratamiento profesional* dado su contexto laboral y demográfico permite orientar acciones de psicoeducación dirigida sin reemplazar la evaluación clínica. Este trabajo implementa un Perceptrón Multicapa (MLP) sobre la encuesta OSMI 2014 (Open Sourcing Mental Illness), un dataset de 1259 respuestas de trabajadores tech que reporta variables laborales (beneficios, políticas, apertura), demográficas (edad, género, autoempleo) y antecedentes (historia familiar, tratamiento previo).

Tarea: clasificación binaria. Variable objetivo `treatment` (Sí / No). **Relevancia profesional:** aplicable directamente a flujos de triaje en plataformas SaaS de psicoeducación. **Restricción ética declarada:** el modelo predice una *intención declarada*, no un diagnóstico clínico — esta distinción es central para uso responsable.

2. Preparación y limpieza del dataset

El dataset original presenta tres problemas conocidos que requirieron limpieza específica: (a) la columna `Age` contiene valores absurdos (negativos y >100) por error de captura; se filtró al rango plausible 18–80 años (8 filas eliminadas); (b) la columna `Gender` es texto libre con más de 40 variantes que se normalizaron a tres categorías (Male: 996, Female: 245, Other: 10); (c) las columnas `state`, `comments`, `Country` y `Timestamp` se descartaron por irrelevancia o alto porcentaje de nulos. Los valores faltantes restantes en variables categóricas se imputaron con la moda. Las variables categóricas se codificaron con one-hot encoding, resultando en un espacio de 44 features.

Ficha técnica resumida

Atributo	Valor
Muestras tras limpieza	1251
Features de entrada (post one-hot)	44
Distribución de clases (<code>treatment</code>)	50,5% Sí / 49,5% No
División Train / Val / Test	875 / 188 / 188 muestras (estratificada)
Normalización	StandardScaler (z-score) ajustado solo en train

Por qué tres conjuntos: el conjunto de validación permite monitorear overfitting y aplicar early stopping sin contaminar el conjunto de prueba. El test del 15% se mantiene como caja cerrada y solo se abre al final para reportar métricas honestas de generalización.

3. Arquitectura del MLP

Se diseñó un MLP de tres capas ocultas en arquitectura tipo embudo ($64 \rightarrow 32 \rightarrow 16$ neuronas), con activación ReLU en capas ocultas y sigmoide en la capa de salida. La compresión progresiva fuerza al modelo a aprender representaciones más abstractas en cada capa. ReLU se eligió como estándar moderno por su eficiencia y resistencia al vanishing gradient. La sigmoide en la salida mapea a una probabilidad calibrada en $[0,1]$, compatible con `binary_crossentropy`. **Total de parámetros entrenables: 5.505.**

Optimizador: Adam con learning rate inicial de 0,001. Adam combina momentum y RMSProp con adaptación interna del learning rate, ofreciendo convergencia rápida y estable. **Batch size:** 32. **Épocas máximas:** 150, con criterio de detención específico por modelo.

4. Experimento complementario: comparación de estrategias de regularización

Se eligió **regularización** como eje de análisis complementario. La justificación es doble: con 1251 muestras post-limpieza y 44 features post-encoding, la razón muestras/features es de aproximadamente 28, lo que ubica al modelo en zona conocida de alto riesgo de overfitting. Adicionalmente, en contextos de salud mental, un modelo sobreajustado que aprende correlaciones espurias del subgrupo de entrenamiento es peligroso al desplegarse en poblaciones distintas. Se entrenaron cuatro variantes manteniendo idéntica la arquitectura, optimizador, batch size y semilla aleatoria (SEED=42):

#	Variante	Configuración	Mecanismo
1	Baseline	Sin regularización	Referencia para medir el efecto
2	L2	$\lambda = 0,01$	Penaliza pesos grandes en el loss
3	Dropout	rate = 0,3	Apaga 30% de neuronas aleatoriamente
4	Early Stopping	paciencia = 15	Detiene si val_loss no mejora

Curvas de aprendizaje por estrategia de regularización (datos reales OSMI 2014)




Figura 1. Curvas de aprendizaje por estrategia. El baseline muestra divergencia clara entre train y validation desde épocas tempranas (overfitting evidente). Las tres técnicas de regularización mantienen las curvas más cercanas. Early Stopping detuvo el entrenamiento tras 19 épocas al detectar estancamiento en val_loss, mucho antes que las otras variantes que corrieron las 150 épocas completas.

5. Resultados sobre conjunto de prueba

Tras entrenar las cuatro variantes, se evaluó cada modelo sobre el conjunto de prueba (15% reservado, $n=188$), nunca visto durante el entrenamiento ni el ajuste de hiperparámetros. Se reportan cinco métricas:

Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Baseline	0,6915	0,6947	0,6947	0,6947	0,7736
L2 ($\lambda=0,01$)	0,6755	0,6977	0,6316	0,6630	0,7393
Dropout (0,3)	0,7447	0,7527	0,7368	0,7447	0,7903
Early Stopping	0,7553	0,8101	0,6737	0,7356	0,8222

Tabla 1. Métricas reales sobre conjunto de prueba (verde = mejor modelo por F1-Score).




Figura 2. Matrices de confusión. El baseline comete más errores en ambos sentidos. Dropout logra el mejor balance entre verdaderos positivos y verdaderos negativos. Early Stopping tiene alta precisión pero menor recall, lo que en aplicaciones de salud mental implica mayor riesgo de no identificar a personas que sí buscarían ayuda.

Análisis del impacto de la regularización

Resultado principal — Dropout fue la mejor estrategia con F1-Score de 0,7447, superando al baseline (0,6947) y a Early Stopping (0,7356). Este hallazgo desafía la intuición inicial de que Early Stopping ganaría por su simplicidad. La razón es que Early Stopping detuvo en la época 19 — muy temprano — sacrificando recall (0,6737) para preservar precisión (0,8101). Dropout, en cambio, permite entrenamiento completo (150 épocas) pero introduce ruido estocástico que evita la memorización, logrando el mejor balance recall-precision.

L2 fue contraproducente en este caso (0,6630 vs baseline 0,6947). La penalización $\lambda=0,01$ resultó demasiado agresiva para el tamaño del dataset, llevando al modelo hacia underfitting. Un λ menor (ej. 0,001) probablemente daría mejores resultados — esto es una vía de mejora identificada.

6. Discusión y conclusiones

Los resultados confirman empíricamente que el overfitting es un riesgo real en datasets pequeños con muchas features categóricas codificadas, pero contradicen la suposición simplista de que cualquier regularización mejora el modelo. **La elección del mecanismo y su intensidad importan tanto como la decisión de regularizar.** En este experimento: (i) **Dropout** resultó la opción más robusta porque introduce variabilidad estocástica sin sesgar sistemáticamente los pesos; (ii) **Early Stopping** fue muy conservador y detuvo el entrenamiento antes de que el modelo aprovechara su capacidad — útil cuando se prioriza velocidad de entrenamiento o se sospecha overfitting agresivo, pero no óptimo aquí; (iii) **L2 con $\lambda=0,01$** sobre-restrigió los pesos en un dataset ya pequeño, produciendo underfitting. Esto refleja un principio operativo del deep learning: *los hiperparámetros de regularización deben calibrarse al problema, no asumirse.*




Figura 3. Curvas ROC. Early Stopping logra el mejor AUC (0,822), seguido por Dropout (0,790). AUC mide el desempeño a través de todos los umbrales; si en producción se ajustara el umbral de decisión (no fijo en 0,5), Early Stopping podría ser competitivo. La elección del modelo final depende del umbral operativo deseado.

Lecciones aprendidas y trabajo futuro

Conceptual: el experimento desafía la heurística "regularizar siempre ayuda". El baseline obtuvo $F1=0,6947$, L2 lo empeoró, Early Stopping mejoró ligeramente y solo Dropout mejoró sustancialmente. La regularización es un eje de control válido, pero su efecto depende del problema específico. **Operativo:** en contextos de salud mental, recall importa más que accuracy porque el costo asimétrico de los errores favorece la sensibilidad. Dropout entregó el mejor recall (0,7368), lo cual lo hace preferible para esta aplicación específica. **Ético:** el modelo predice *intención declarada* en una muestra autoseleccionada de trabajadores tech occidentales. Generalizar sus predicciones a otros contextos requiere validación con poblaciones representativas y supervisión clínica.

Limitaciones reconocidas y trabajo futuro: (i) probar λ menores en L2 (0,001 - 0,0001) y rates de Dropout distintos (0,2 - 0,5) para encontrar el óptimo; (ii) implementar validación cruzada k-fold con múltiples semillas para reducir varianza en las métricas reportadas; (iii) comparar contra baselines más simples (regresión logística, random forest) para validar que la complejidad del MLP está justificada; (iv) explorar técnicas de manejo de variables categóricas alternativas al one-hot (target encoding, embeddings entrenables).

Referencias

- [1] OSMI (Open Sourcing Mental Illness). *Mental Health in Tech Survey 2014*. Disponible en Kaggle: kaggle.com/datasets/osmi/mental-health-in-tech-survey
- [2] Scikit-learn developers. *Neural network models (supervised)*. scikit-learn.org/stable/modules/neural_networks_supervised.html
- [3] TensorFlow Authors. *TensorFlow Core — Keras API*. tensorflow.org/api_docs/python/tf/keras
- [4] Srivastava, N. et al. (2014). *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Machine Learning Research, 15:1929–1958.