

Red Neuronal Convolucional para Reconocimiento de Expresiones Faciales (FER-2013)

J. Quizamánchuro Fuel^a, G. Calahorrano Guayasamin^a y D. Perez Cedillo^a

^a Universidad Internacional del Ecuador

Profesor: J. Rodriguez Chivata

Código fuente

↪ [Notebook del Proyecto en GitHub](#)

1. Resumen del Problema

El reconocimiento automático de expresiones faciales es un componente recurrente en sistemas asistidos de psicoeducación, monitoreo de bienestar emocional y evaluación de intervenciones digitales. Identificar correctamente la emoción aparente en una imagen permite, por ejemplo, ajustar dinámicamente el tono de una intervención psicoeducativa o disparar alertas de seguimiento clínico cuando se observan patrones sostenidos de afecto negativo.

Este trabajo implementa una **Red Neuronal Convolutacional (CNN)** sobre el dataset *FER-2013* (Facial Expression Recognition 2013), publicado en el ICML 2013 Workshop on Representation Learning. El dataset contiene 35.887 imágenes de rostros humanos en escala de grises (48×48 px), etiquetadas en siete expresiones emocionales: *angry*, *disgust*, *fear*, *happy*, *neutral*, *sad* y *surprise*.

Tarea: Clasificación multiclase (7 clases).

Relevancia profesional: Aplicable a flujos de psicoeducación asistida y validación visual de intervenciones.

Restricción ética declarada: el modelo clasifica *patrones visuales*, no estados emocionales internos — una expresión etiquetada como *happy* no garantiza alegría real (Barrett et al., 2019). Cualquier uso aplicado requiere supervisión clínica.

Continuidad con la Semana 1. La entrega previa abordó datos tabulares con un MLP. El docente observó: “*trabajar más del lado de las características; OHE no es la solución*” y “*iniciar con un modelo menos complejo e ir analizando comportamientos*”. Esta semana aplica ambos puntos: la CNN **aprende su propia jerarquía de features** (bordes → texturas → partes de cara → expresiones), eliminando el OHE manual; y el experimento parte de un baseline mínimo, añadiendo complejidad por etapas.

2. Preparación del dataset

FER-2013 se distribuye como carpetas por clase para **train** (28.709 imágenes) y **test** (7.178 imágenes). La preparación realizada fue:

- **Splits:** `data/train` se dividió 85 % / 15 % (semilla 42) en `train` y `validation`; `data/test` se mantiene como caja cerrada y solo se abre al final.

- **Carga:** `image_dataset_from_directory` con `color_mode='grayscale'`, `image_size=(48,48)`, `batch_size=64`.
- **Normalización:** `Rescaling(1/255)` aplicado *dentro* del modelo, garantizando que el pre-proceso viaja con los pesos al serializar.
- **Etiquetas:** enteras (`label_mode='int'`) con pérdida `sparse_categorical_crossentropy` — evitando el OHE de 7 dimensiones en línea con el feedback de Semana 1.

Cuadro 1: Ficha técnica resumida

Atributo	Valor
Imágenes totales	35.887 (28.709 train / 7.178 test)
Resolución	48×48 px, escala de grises
Clases	7 (angry, disgust, fear, happy, neutral, sad, surprise)
Split efectivo	24.402 train / 4.307 val / 7.178 test
Clase mayoritaria	happy (7.215 imágenes en train)
Clase minoritaria	disgust (436 imágenes en train)
Ratio mayor/menor	16,5 : 1
Manejo del desbalance	<code>class_weight='balanced'</code> (variantes B y C)

Sobre el desbalance. El ratio 16,5 a 1 entre *happy* y *disgust* es severo. Un modelo entrenado sin compensación tiende a predecir *happy* por defecto y a obtener buena *accuracy* bruta a costa de un recall nulo sobre las clases minoritarias. La estrategia adoptada fue ponderar la pérdida por clase con `compute_class_weight('balanced')`, aplicada solo a las variantes B y C para que cualquier mejora sea atribuible a la decisión.

3. Arquitectura de la CNN

Se diseñó una arquitectura convolucional **deliberadamente conservadora** en respuesta al feedback de Semana 1 (“*iniciar simple*”). Toda variante comparte la misma topología base; la única diferencia entre A, B y C es la activación de *flags* sobre regularización y aumentación. La definición se centraliza en una sola función `build_cnn(...)` configurable.

- **Entrada:** `Input(48,48,1)` → [aumentación opcional] → `Rescaling(1/255)`.
- **Bloque Conv-1:** `Conv2D(32, 3×3, ReLU)` → `[BatchNorm]` → `MaxPool(2×2)` →

[Dropout(0,25)].

■ **Bloque Conv-2:** Conv2D(64, 3×3, ReLU) → [BatchNorm] → MaxPool(2×2) → [Dropout(0,25)].

■ **Cabeza:** Flatten → Dense(128, ReLU) → [Dropout(0,5)] → Dense(7, Softmax).

Optimizador: Adam con $\text{learning_rate} = 10^{-3}$.

Pérdida: `sparse_categorical_crossentropy`.

Batch size: 64.

Épocas máximas: 25, con `EarlyStopping(patience=5, restore_best_weights=True)` y `ReduceLROnPlateau(factor=0,5, patience=3, min_lr=10-6)`.

Reproducibilidad: semilla 42 sembrada en `numpy`, `tf` y `keras`.

Hardware: entrenamiento sobre Apple M1 Max con aceleración Metal vía `tensorflow-metal`.

4. Experimento: tres variantes incrementales

Se entrenan **tres variantes incrementales** de la misma arquitectura, cada una añadiendo una sola familia de cambios sobre la anterior. Esta estructura $A \rightarrow B \rightarrow C$ hace cada mejora atribuible a una decisión específica y auditable, materializando la indicación del docente de “*analizar comportamientos*” antes de subir complejidad.

Cuadro 2: Variantes evaluadas y mecanismos activados

Variante	Configuración y mecanismo
A — Baseline	Sin BatchNorm, sin Dropout, sin aumentación. Referencia para medir el efecto de las defensas.
B — Regularizada	+ BatchNorm tras cada Conv2D + Dropout (0,20 en conv, 0,30 en densa). Calibración <i>moderada</i> tras descartar empíricamente una versión con Dropout 0,25/0,50 + <code>class_weight='balanced'</code> que produjo underfitting.
C — Aumentada	B + bloque <code>RandomFlip</code> horizontal, <code>RandomRotation(0,10)</code> y <code>RandomZoom(0,10)</code> al inicio del modelo. Amplía el <i>train set efectivo</i> .

Hipótesis de trabajo. (i) El baseline mostrará divergencia entre *train* y *validation* hacia las épocas 8–12 y un recall bajo sobre `disgust`. (ii) La regularización *calibrada* (BN + Dropout moderado) cerrará la brecha train/val y mejorará F1-macro frente al baseline. (iii) La aumentación, sobre B, puede ir en dos direcciones según la red sea pequeña o grande: añadir varianza útil (*mejora*) o sobre-regularizar al combinarse con BN y Dropout (*deterioro*). El experimento

prueba cuál ocurre aquí.

Iteración previa descartada. Una primera ejecución con `class_weight='balanced'` aplicado a B y C y Dropout(0,25 conv / 0,50 dense) produjo pérdidas iniciales de ≈ 25 en B y ≈ 23 en C (vs $\approx 1,7$ en A), causadas por el peso $9,4\times$ sobre `disgust` amplificando los gradientes en un régimen donde BN aún no estabiliza. Las tres variantes terminaron con un F1-macro decreciente (A=0,43; B=0,36; C=0,24). Se reconfiguraron B y C eliminando `class_weight` y reduciendo Dropout, dejando a la métrica F1-macro — y no a un peso explícito — como salvaguarda contra modelos que ignoren clases minoritarias. Este episodio confirma empíricamente el principio operativo identificado en la Semana 1 con L2 ($\lambda = 0,01$): *los hiperparámetros de regularización deben calibrarse al problema, no asumirse*.




Figura 1: Curvas de aprendizaje (loss y accuracy, train vs. val) por variante. El baseline (fila 1) muestra divergencia moderada y converge en 12 épocas. La variante B (fila 2) corre las 25 épocas completas y alcanza la mejor *val_accuracy* ($\approx 0,76$ en la época 23). La variante C (fila 3) muestra mayor oscilación durante el entrenamiento por la estocasticidad de la aumentación, y aunque su *val_accuracy* pico es comparable a B, su transferencia a test resulta menor (ver Cuadro 3 y Sección 5.1).

5. Resultados sobre conjunto de prueba

Las tres variantes se evalúan sobre *data/test* ($n=7.178$), nunca visto durante el entrenamiento ni el ajuste de hiperparámetros. Las cuatro métricas reportadas son:

- **Accuracy** — proporción de aciertos totales; engañosa con desbalance fuerte.
- **Precision (macro)** — promedio simple por clase; no pondera por tamaño.
- **Recall (macro)** — promedio simple por clase; sensible al comportamiento sobre `disgust`.
- **F1 (macro)** — media armónica; **métrica priorizada** del experimento, definida antes de mirar los

resultados.

Cuadro 3: Métricas sobre el conjunto de prueba (n=7.178). Verde = mejor modelo por F1-macro.

Modelo	Acc.	Prec.	Rec.	F1
A — Baseline	0,4844	0,4493	0,4462	0,4292
B — Regularizada	0,5415	0,5029	0,5112	0,5032
C — Aumentada	0,3938	0,3409	0,3556	0,2920



Figura 2: Matrices de confusión normalizadas por filas (recall por clase). La fila **disgust** es el termómetro principal: el baseline obtiene un recall sobre **disgust** de 0,38 (sorprendentemente alto sin compensación explícita), y la variante B lo mantiene por encima de 0,3 mientras eleva el promedio macro al 0,51. La variante C presenta el patrón inverso: aunque su *val_accuracy* pico era comparable a B, su recall macro en test cae a 0,36, consistente con un modelo que durante el entrenamiento ve un train set más variado pero generaliza peor a la distribución exacta de test.

5.1. Análisis del impacto de cada estrategia

Sobre el baseline (variante A F1=0,4292). El modelo aprende rápidamente y, contra la hipótesis inicial, no colapsa a la clase mayoritaria: obtiene un recall sobre **disgust** de 0,38 y un F1 por clase razonable (con **happy** 0,67 y **surprise** 0,62 como las más fáciles, y **angry** 0,24 como la más difícil). **EarlyStopping** corta en la época 12 al detectar estancamiento, lo cual sugiere que el modelo ya había agotado lo que podía aprender sin defensas. Sirve como referencia honesta: una CNN simple sobre FER-2013 alcanza ~48 % de accuracy y ~43 % de F1-macro *sin* regularización ni aumentación.

Sobre la regularización (variante B F1=0,5032, ganadora). BatchNorm estabiliza la distribución de activaciones entre lotes, y Dropout moderado (0,20 conv / 0,30 dense) introduce ruido estocástico que previene la coadaptación de neuronas sin asfixiar el aprendizaje. El resultado es un salto de +7,4 puntos de F1-macro y +5,7 puntos de accuracy sobre el baseline, alcanzando una *val_accuracy* de 0,76 en la mejor época. La calibración del Dropout fue crítica: una versión inicial con 0,50 produjo el efecto opuesto (underfitting con F1=0,36) — el modelo es lo bastante pequeño como para que una regularización agresiva lo deje sin capacidad de aprendizaje.

Sobre la aumentación (variante C F1=0,2920). Contra la hipótesis inicial, añadir RandomFlip + RandomRotation + RandomZoom encima de la regularización *no* mejoró el resultado: el F1-macro cayó

a 0,29, por debajo incluso del baseline. La curva de aprendizaje muestra que durante el entrenamiento la *val_accuracy* llegó a 0,70 (comparable a B), pero la transferencia a test fue mucho peor. Dos factores probables: (i) la aumentación, sobre una red ya regularizada, suma demasiada estocasticidad para una arquitectura de solo 2 bloques convolucionales con 1,2 M parámetros — el modelo se queda con *train_acc* de 0,45 frente a 0,60 de B, signo claro de underfitting; (ii) un comportamiento conocido al combinar BatchNormalization con *restore_best_weights* en **EarlyStopping**: las estadísticas *moving* de BN no se restauran al estado de la mejor época, generando inconsistencia entre los pesos restaurados y las *running stats* usadas en inferencia. Este es un hallazgo interesante para la limitación reconocida en la Sección 6.



Figura 3: Errores típicos de la variante B (la ganadora por F1-macro). Una porción no trivial de los errores es *interpretable*: **fear** confundido con **surprise** (ambas con ojos muy abiertos), **sad** confundido con **neutral** (ambas con boca cerrada y cejas relajadas). Esto es consistente con el techo informacional del dataset (accuracy humana sobre FER-2013 ≈65 %) y no necesariamente con una arquitectura insuficiente.

6. Discusión y conclusiones

El experimento aporta dos hallazgos empíricos que matizan la intuición inicial. Primero, la regularización *bien calibrada* (variante B) mejora claramente al baseline (+7,4 puntos de F1-macro), lo cual confirma su valor cuando la arquitectura tiene capacidad suficiente. Segundo, las defensas contra overfitting *no son aditivas*: añadir aumentación sobre una red ya regularizada (variante C) produjo deterioro en lugar de mejora, en una arquitectura pequeña con ~1,2 M de parámetros.

Resultado observado: A < B > C. La progresión esperada A → B → C *monotónicamente creciente* no se confirmó. En su lugar, observamos un máximo en B y un retroceso en C. Esto es coherente con dos hechos: (i) el modelo es lo bastante pequeño como para que una segunda capa de regulariza-

ción lo lleve a underfitting (*train_acc* de C: 0,45 vs B: 0,60); (ii) la interacción de `BatchNormalization` con `restore_best_weights` introduce inconsistencia entre los pesos restaurados de la mejor época y las *running statistics* acumuladas durante todo el entrenamiento.

Lejos de invalidar el experimento, este resultado lo refuerza: el feedback de la Semana 1 ya había documentado un patrón análogo (L2 con $\lambda = 0,01$ empeoró el baseline). La lección recurrente es que cada técnica de regularización requiere calibración en su escala propia y que las defensas se suman *no linealmente* al combinarse en arquitecturas pequeñas. La estrategia metodológica de *añadir una sola familia de cambios por iteración* — el feedback explícito del docente — es precisamente lo que permitió aislar este efecto y atribuirlo a la decisión de añadir aumentación, sin ambigüedad.

6.1. Lecciones aprendidas y trabajo futuro

Conceptual: la decisión de centralizar la arquitectura en una sola función `build_cnn(...)` con *flags* es lo que vuelve atribuible cada mejora. Sin esta restricción de diseño, una variante mejor no permitiría saber *cuál* de las decisiones produjo el efecto. **Operativo:** en contextos psicoeducativos — aplicación natural de este modelo — el F1-macro es preferible a la accuracy precisamente porque trata las siete emociones como igualmente relevantes; ignorar *disgust* o *fear* sería problemático para una aplicación clínica asistida. **Ético:** este modelo clasifica patrones visuales en imágenes, no estados emocionales internos (Barrett et al., 2019). FER-2013 tiene además ruido de etiquetado documentado (accuracy humana $\approx 65\%$). Cualquier uso aplicado requiere validación con poblaciones representativas y supervisión clínica.

Limitaciones reconocidas y trabajo futuro:

- I. Probar arquitecturas más profundas (3 bloques convolucionales, filtros $32 \rightarrow 64 \rightarrow 128$) para cuantificar el aporte real de la profundidad. Una red más grande probablemente absorbería la aumentación de C sin caer en underfitting.
- II. Investigar el comportamiento de `BatchNormalization` con `restore_best_weights`: re-entrenar la variante C *sin* restauración para confirmar si el gap val-test de C se debe a inconsistencia de *moving stats*.
- III. Implementar validación cruzada *k-fold* con múltiples semillas para reducir varianza en las métricas reportadas (especialmente relevante dado el comportamiento atípico de C).
- IV. Explorar estrategias alternativas de manejo del desbalance: *oversampling* con SMOTE adaptado a imágenes, o muestreo balanceado por lote — evitando el efecto desestabilizador que tuvo `class_weight` en este experimento.
- V. **Semana 3 — Transfer Learning:** cargar una red pre-entrenada (MobileNetV2 sobre ImageNet o VGG-Face sobre rostros), congelar las convolucionales y re-entrenar la cabeza para FER-2013. La hipótesis de cierre es que el transfer aportará una

mejora $\geq +5$ puntos de F1-macro sobre la mejor variante de esta semana (B con $F1=0,5032$), gracias a representaciones visuales generales que una CNN entrenada desde cero sobre ~ 29.000 imágenes no alcanza a aprender por sí sola.

7. Cierre del feedback profesoral (40/40)

Sección añadida en la entrega final del cuatrimestre para documentar cómo el feedback sobre esta práctica se aplicó en Semana 3.

Comentario del docente. “*Felicitaciones la práctica ha estado muy bien desarrollada y explicada. (...) Yo quitaría de la red las capas de MaxPooling basado en que la imagen es $48 \times 48 \times 1$ (poca información); el objetivo principal del pooling es reducir computación pero aquí quizás esté quitando características importantes. (...) Esta semana podrían expandir más la exploración con fine tuning y redes más grandes con regularización adecuada para ver el comportamiento.*”

Acciones aplicadas en Semana 3. (i) El backbone elegido, **MobileNetV2**, *no usa MaxPooling* por diseño emplea `Conv2D(stride=2)` para el downsampling. Adicionalmente las imágenes se redimensionaron a 96×96 RGB. (ii) Toda Semana 3 es una respuesta directa a la segunda sugerencia: backbone de 88 capas ($3 \times$ la profundidad de la CNN actual) entrenado en dos fases con LR diferenciado $1000 \times (1e-3$ en Feature Extraction y $1e-5$ en Fine-Tuning). El delta interno entre fases fue $+3,07$ pp F1, validando empíricamente la estrategia. (iii) Sobre el desbalance: en Semana 3 se evitó deliberadamente reintroducir `class_weight` tras el hallazgo de esta práctica.

Hallazgo cruzado con Semana 3. Sorprendentemente, el Transfer Learning con MobileNetV2/ImageNet **no superó** a la mejor variante de esta semana ($F1=0,3814$ vs $0,5032$). El análisis interno mostró que el fine-tuning sí añadió valor pero el techo del backbone es bajo por mismatch de dominio (ImageNet objetos naturales vs FER-2013 rostros 48×48 grayscale). La intuición del docente sobre el MaxPooling se confirmó válida, pero el cuello de botella efectivo está en otro lado (backbone genérico). Esto refuerza el patrón observado en Semana 1: las técnicas sofisticadas requieren calibración al problema, no se asumen.

Referencias. Goodfellow, I. et al. (2013). *Challenges in Representation Learning*, ICML Workshop. • Ioffe, S. & Szegedy, C. (2015). *Batch Normalization*, arXiv:1502.03167. • Srivastava, N. et al. (2014). *Dropout*, JMLR 15:1929–1958. • Barrett, L. F. et al. (2019). *Emotional Expressions Reconsidered*, Psychological Science in the Public Interest 20(1):1–68.