

Variational Autoencoder (VAE) para Generación de Expresiones Faciales (FER-2013)

J. Quizamánchuro Fuel^a, G. Calahorrano Guayasamin^a y D. Perez Cedillo^a

^a Universidad Internacional del Ecuador

Profesor: J. Rodriguez Chivata

Código fuente

↪ [Notebook del Proyecto en GitHub](#)

1. Resumen del Problema

La generación controlada de rostros con expresiones emocionales tiene aplicación directa en plataformas de psicoeducación asistida por IA: visualizaciones del continuo afectivo, datos sintéticos para entrenamiento sin exposición de identidades, y representaciones compactas del estado emocional para módulos de seguimiento longitudinal.

Este trabajo implementa un **Variational Autoencoder (VAE)** con Keras/TensorFlow sobre el dataset *FER-2013* el mismo conjunto usado en la Semana 2 para clasificación, ahora reorientado a *generación*. El objetivo es aprender un espacio latente continuo de 48 dimensiones que codifique las siete expresiones emocionales del dataset y evaluar tres capacidades generativas: reconstrucción de imágenes reales, generación de caras nuevas desde el prior y interpolación lineal entre puntos del espacio latente.

Arquitectura elegida: VAE (en lugar de GAN).

Justificación principal: el espacio latente continuo del VAE es lo que vuelve útil a la herramienta para **Psico Platform** y para análogos clínicos como el del **Hospital Carlos Andrade Marín** (lectura EIG Campus L-IAA_25_001122). Un GAN produciría rostros más nítidos pero sin espacio latente navegable, la utilidad psicoeducativa se pierde.

Restricción ética declarada: el VAE aprende la *distribución* de los rostros, no instancias específicas. Las muestras generadas son rostros sintéticos. Esto es precisamente lo que vuelve al VAE útil como mecanismo de *privacy-preserving data synthesis*, pero exige no presentarlo como diagnóstico.

Continuidad con las Semanas 1 y 2. En Semana 1 (MLP, OSMI Mental Health, 39/40) el docente observó: “trabajar más del lado de las características; OHE no es la solución”. En Semana 2 (CNN, FER-2013, 40/40) añadió: “quitaría las capas de Max-Pooling porque la imagen es 48x48x3 (poca información)” y “expandir con fine-tuning y redes más grandes”. Esta entrega aplica los tres puntos explícitamente (Sección 3).

2. Preparación del dataset

FER-2013 se distribuye como carpetas por clase. La preparación realizada:

- **Carga:** `image_dataset_from_directory` con `color_mode='grayscale'`, `image_size=(48,48)`, `batch_size=128`.
- **Normalización:** a $[0,1]$ por división entre 255, aplicada en el pipeline `tf.data` antes del entrenamiento.
- **Etiquetas:** se descartan para el entrenamiento (el VAE es no supervisado). Se preservan en una pipeline paralela solo para colorear el t-SNE final.

A diferencia de la Semana 2 donde el desbalance fue el problema central, para un VAE el desbalance es *menos crítico*: el modelo no clasifica, solo aprende a reconstruir. La clase mayoritaria (**happy**) dominará la distribución del espacio latente, pero todas las clases contribuyen al aprendizaje.

Cuadro 1: Ficha técnica resumida

Atributo	Valor
Imágenes totales	35.887 (28.709 train / 7.178 test)
Resolución	48x48 px, escala de grises
Clases	7 (angry, disgust, fear, happy, neutral, sad, surprise)
Normalización	división por 255 $\rightarrow [0,1]$
Dimensión latente	48
Tamaño del modelo	$\approx 1,6$ M parámetros (encoder + decoder)
Hardware	Apple M1 Max con tensorflow-metal

3. Arquitectura del VAE aplicación del feedback

La arquitectura aplica explícitamente las tres observaciones acumuladas del docente:

Cuadro 2: Mapeo feedback acumulado $\rightarrow$ decisión técnica

Feedback	Aplicación
“Más features, menos OHE” (S1)	El espacio latente del VAE es la materialización máxima: la red descubre por sí misma 48 dims que sintetizan toda la variación visual. Cero ingeniería manual.
“Quitar MaxPooling en 48x48” (S2)	Cero MaxPooling2D en el modelo. Downsampling con Conv2D(stride=2) en encoder, upsampling con Conv2DTranspose(stride=2) en decoder.
“Redes más grandes y fine-tuning” (S2)	Modelo de $\approx 1,6$ M parámetros (1,3x la CNN de Semana 2). Sección 7 propone transfer learning con StyleGAN2-FFHQ.

Encoder. $\text{Input}(48,48,1) \rightarrow \text{Conv2D}(32, 3 \times 3, s=2) \rightarrow \text{Conv2D}(64, 3 \times 3, s=2) \rightarrow \text{Conv2D}(128, 3 \times 3, s=2) \rightarrow \text{Flatten} \rightarrow \text{Dense}(256) \rightarrow$ dos ramas paralelas $\text{Dense}(48)$ para z_μ y $z_{\log \sigma^2}$.

Truco de reparametrización. El núcleo conceptual del VAE: para entrenar end-to-end con backpropagation necesitamos muestrear $z \sim \mathcal{N}(z_\mu, e^{z_{\log \sigma^2}})$ de forma *diferenciable*. La reformulación es $z = z_\mu + e^{0.5 \cdot z_{\log \sigma^2}} \cdot \epsilon$, con $\epsilon \sim \mathcal{N}(0, I)$ como fuente externa de aleatoriedad sin gradiente.

Decoder. Espejo del encoder: $\text{Dense}(6 \times 6 \times 128) \rightarrow \text{Reshape} \rightarrow$ tres Conv2DTranspose con $\text{stride}=2$ ($64 \rightarrow 32 \rightarrow 1$) y activación **sigmoid** en la salida para producir píxeles en $[0, 1]$.

Pérdida ELBO. $\mathcal{L} = \mathcal{L}_{\text{recon}} + \beta \cdot \mathcal{L}_{\text{KL}}$, con $\mathcal{L}_{\text{recon}} = \text{BCE}(x, \hat{x}) \cdot 48^2$ y $\mathcal{L}_{\text{KL}} = -\frac{1}{2} \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$.

4. Calibración iterativa del entrenamiento

El entrenamiento del VAE **no funcionó a la primera**. Tres iteraciones fueron necesarias para llegar a un modelo estable. Esta sección documenta el proceso porque es un hallazgo pedagógico relevante (paralelo al patrón “*regularizar más no siempre ayuda*” de Semana 1 con L2).

Cuadro 3: Iteraciones de calibración y patología observada

#	Config	Patología observada
1	$\beta = 1$, $\text{lr}=10^{-3}$, 40 ep	Colapso a NaN: todos los pesos del encoder se vuelven NaN tras pocas épocas. Causa: $\exp(0.5 \cdot z_{\log \sigma^2})$ sin clip explota.
2	$\beta = 0.5$, $\text{lr}=5 \cdot 10^{-4}$, $\text{clipnorm}=1$, 25 ep	Posterior collapse + recuperación catastrófica: KL ≈ 0 hasta epoch 20, luego explota a $\text{KL} \approx 3,400$. Reconstrucciones colapsan a blobs.
3	$\beta = 0.5$, $\text{lr}=5 \cdot 10^{-4}$, $\text{clipnorm}=1$, 18 ep	Saludable. Recon 1490 $\rightarrow$ 1335, KL estable en ≈ 10 , sin explosión. Reconstrucciones reconocibles.

Protecciones numéricas añadidas (entre iteraciones 1 y 2).

- `tf.clip_by_value(z_log_var, -7, 7)` en la capa Sampling y en el cálculo de KL.
- `tf.clip_by_value(reconstruction, 1e-7, 1-1e-7)` antes de BCE para evitar $\log(0)$.
- `Adam(clipnorm=1.0)` para limitar la norma del gradiente.

Las iteraciones 1 y 2 son evidencia empírica de que el VAE estándar es *numéricamente frágil* un punto que el paper original de Kingma & Welling (2014) reconoce y que se ha estudiado extensamente bajo el término *posterior collapse*.

5. Resultados

Pérdidas finales (iteración 3, epoch 18).

- Total ELBO:** 1340,38
- Reconstrucción ($\text{BCE} \times 48^2$):** 1334,88 ($-10,5\%$ desde la primera época)
- KL divergencia:** 10,99 (estable, sin explosión)



Figura 1: Curvas de aprendizaje. La pérdida total y la reconstrucción descienden monótonicamente; la KL muestra un pico esperable en las primeras épocas (mientras el encoder “despierta” del posterior collapse) y luego se estabiliza alrededor de 10. Compárese con el patrón patológico de la iteración 1, donde KL explotaba más allá de epoch 30.

5.1. Reconstrucción de imágenes no vistas



Figura 2: Reconstrucciones del VAE sobre 8 imágenes del test set (nunca vistas durante el entrenamiento). Fila superior: originales. Fila inferior: reconstruidas. Se observan rostros borrosos pero con estructura facial coherente: cabeza, área de ojos y boca son reconocibles. La borrosidad es característica del VAE estándar con pérdida BCE pixel a pixel (limitación conocida en la literatura).

5.2. Generación desde el prior $\mathcal{N}(0, I)$



Figura 3: 16 caras sintéticas generadas muestreando $z \sim \mathcal{N}(0, I)$ y decodificando directamente. Ninguna existe en el dataset. Cada cara es visualmente diferente evidencia de que el espacio latente está bien cubierto por la posterior aprendida.

5.3. Interpolación happy $\rightarrow$ sad




Figura 4: Interpolación lineal entre z_{happy} y z_{sad} en 8 pasos. La transición es *suave pero sutil*: los rostros intermedios cambian poco visualmente. Esto es consistente con el valor bajo de KL (≈ 10): el modelo no separa fuertemente las clases en el espacio latente, así que la línea recta entre dos puntos atraviesa rostros muy similares al promedio.

5.4. Estructura del espacio latente




Figura 5: Proyección t-SNE de 2.000 vectores latentes del test set, coloreados por clase. Los clusters por clase **no** son claramente distinguibles: todas las clases se mezclan en una nube relativamente uniforme. Esto es esperable en un VAE no supervisado con KL bajo: el modelo aprende la *distribución global* de rostros sin priorizar separabilidad por clase. La solución estructural es Conditional VAE (trabajo futuro).

6. Discusión y conclusiones

El experimento valida empíricamente cuatro afirmaciones:

1. **El truco de reparametrización funciona como teoría predice.** La pérdida ELBO desciende monótonicamente y el modelo aprende a reconstruir rostros reconocibles desde un espacio latente regularizado.
2. **El VAE estándar es numéricamente frágil.** Sin clips de `log_var` y de la salida BCE, el modelo colapsa a NaN en pocas épocas. Sin calibración fina de β y épocas, entra en posterior collapse. Esto no es un fracaso experimental: es una característica conocida de la familia VAE.
3. **La borrosidad de las reconstrucciones es inherente al VAE con pérdida BCE.** Se promedia entre múltiples soluciones plausibles. Mitigable solo con cambios arquitectónicos profundos (VAE-GAN híbrido, modelos de difusión, transfer learning).
4. **La interpolación es suave aunque sutil** en este modelo. Una interpolación más expresiva requiere mayor uso del espacio latente: un Conditional VAE separaría las clases en el latente y haría la interpolación más narrativa.

Lecciones aplicadas al feedback acumulado.

- (*Semana 1, “más features”*): el espacio latente del VAE es la materialización máxima del principio: features completamente aprendidas, cero ingeniería manual.
- (*Semana 2, “sin MaxPooling”*): aplicado al 100 %. `Conv2D(stride=2)` y `Conv2DTranspose(stride=2)` preservan in-

formación que el pooling descartaría en imágenes 48×48 .

- (*Semana 2, “redes más grandes”*): red de 1,6 M parámetros ($1,3 \times$ la CNN previa). La sección de trabajo futuro propone el siguiente salto natural (StyleGAN2 con ~ 30 M).

Conexión con LBD Psico Platform. Tres aplicaciones directas del VAE entrenado:

- Representación compacta del afecto facial** 48 dimensiones frente a 2.304 píxeles. Input estandarizado para módulos de seguimiento longitudinal sin almacenar imágenes brutas (mejora privacidad).
- Interpolación afectiva como recurso psico-educativo** herramienta visual para mostrar a usuarios que las emociones existen en un continuo, no en categorías discretas. Útil en psicoeducación sobre depresión y ansiedad.
- Generación de datos sintéticos preservando privacidad** análogo directo al caso HCAM (lectura EIG Campus L-IAA_25_001122). Permite entrenar modelos downstream sin exponer expedientes reales.

Visual Concepts with a Constrained Variational Framework, ICLR. • Karras, T. et al. (2019). *A Style-Based Generator Architecture for GANs (StyleGAN)*, CVPR. • Goodfellow, I. et al. (2013). *Challenges in Representation Learning*, ICML Workshop. (FER-2013) • Barrett, L. F. et al. (2019). *Emotional Expressions Reconsidered*, Psychological Science in the Public Interest 20(1):1–68. • Lectura EIG Campus L-IAA_25_001122 *VAEs para generación de imágenes médicas sintéticas (HCAM)*.

7. Limitaciones y trabajo futuro

Limitaciones reconocidas:

- Borrosidad de las reconstrucciones (intrínseco al VAE+BCE).
- Interpolación sutil el modelo no separa fuertemente las clases en el latente.
- Resolución baja (48×48 nativa).
- Sesgo del dataset (FER-2013 fue recolectado de Google Images en 2013).

Trabajo futuro (en orden de prioridad):

- Conditional VAE (CVAE)** condicionar la generación por clase ($z, \text{clase} \rightarrow x$). Solución directa al problema de interpolación sutil: permitiría “genera una cara **happy**” explícitamente y separaría las clases en el espacio latente.
- Transfer learning con StyleGAN2-FFHQ** usar el generador pre-entrenado en 70.000 rostros FFHQ de alta resolución como decoder. Entrenar solo un encoder hacia su espacio latente $\mathcal{W}^+$. Resuelve simultáneamente la borrosidad y la baja resolución. **Esta es la continuación más prometedora** y aborda directamente el feedback de Semana 2 sobre redes más grandes + fine-tuning.
- β -VAE con $\beta < 0,5$** para mejorar reconstrucción a costa de regularización. Útil si la prioridad es nitidez sobre generación coherente desde prior.
- Aplicación clínica (caso HCAM)** replicar el experimento del Hospital Carlos Andrade Marín: entrenar el VAE en imágenes médicas (radiografías, dermatología) para generar datasets sintéticos sin riesgo de exposición de pacientes.

Referencias. Kingma, D. P., & Welling, M. (2014). *Auto-Encoding Variational Bayes*, arXiv:1312.6114. (Paper original VAE.) • Higgins, I. et al. (2017). *β -VAE: Learning Basic*